

Investigación de la Influencia de Biomarcadores y Factores Demográficos en Diabetes

Isabelle Archer, Lucía del Carmen Fito Fito, Iván Navarro Martínez, Ruben Saiz López (Grupo B1-08)

2026-04-12

Exploración y preparación de la BBDD

Descripción y naturaleza de las variables

Cargamos los datos. Se han registrado 371 observaciones iniciales.

Creamos una tabla descriptiva de las variables presentes en la base de datos, indicando su tipo (numérica o categórica) y una breve descripción de cada una. Esta tabla es fundamental para entender el contexto de cada variable y su posible relevancia y uso en el análisis posterior.

##	variable	tipo	
## pregnant	pregnant	numerical	
## glucose	glucose	numerical	
## pressure	pressure	numerical	
## triceps	triceps	numerical	
## insulin	insulin	numerical	
## mass	mass	numerical	
## pedigree	pedigree	numerical	
## age	age	numerical	
## diabetes	diabetes	categorical	
## vegdiet	vegdiet	categorical	
## cholesterol	cholesterol	numerical	
## leptin	leptin	numerical	
## CRP	CRP	numerical	
##			descripcion
## pregnant			Numero de embarazos previos
## glucose			Glucosa en plasma (mg/dL)
## pressure			Presion arterial diastolica (mm Hg)
## triceps			Grosor del pliegue cutaneo del triceps (mm)
## insulin			Insulina serica a las 2 horas de la prueba (mug/ml)
## mass			Indice de Masa Corporal
## pedigree	Puntuacion de la carga genetica basada en la historia familiar		
## age			Edad de la paciente en anyos
## diabetes			Si tiene o no diabetes (neg=Sano, pos=Afectado)
## vegdiet			Dieta vegana (Yes=Vegano, No=Dieta omnivora)
## cholesterol			Niveles de colesterol total en sangre (mg/dL)
## leptin			Niveles de leptina serica (ng/mL), regula saciedad
## CRP			Proteina C Reactiva en sangre (mg/L), mide inflamacion

Hay 13 variables en total, de las cuales 11 son numéricas (biomarcadores y edad) y 2 son categóricas binarias (diabetes y vegdiet). La variable objetivo es **diabetes**, que indica si el paciente tiene o no diabetes.


Análisis descriptivo

Hemos comprobado que no hay valores faltantes (NA) en ninguna de las variables, lo que facilita el análisis posterior sin necesidad de imputación o eliminación de casos.

Primero, realizamos un análisis descriptivo de las variables numéricas. Esto nos permite entender la distribución de cada variable y detectar posibles valores atípicos o rangos inconsistentes. En la variable **pregnant**, se observa que el máximo número de embarazos es 15, lo que podría indicar la presencia de casos extremos o un valor inconsistente en la base de datos. La variable **insulin** muestra una gran variabilidad, con un máximo de 744 mug/ml fuera del rango esperado, lo que podría afectar el análisis si no se maneja adecuadamente. El resto de las variables están dentro de rangos esperados, pero muestran una amplia dispersión.

Como todas las variables categóricas varían suficientemente, lo que significa que son variables aleatorias y tiene sentido incluirlas en el análisis, se las deja todas.

Ahora, analizamos si alguna variable tiene valores anómalos mediante un análisis univariante. Para esto, se han generado diagramas de caja (boxplots) para cada variable numérica, utilizando una escala logarítmica en el eje y para facilitar la visualización de los datos con rangos muy dispares.



Se observa que las variables **insulin**, **pedigree** y **leptin** tienen muchos valores anómalos. Después de investigar sus distribuciones, no se detectan inconsistencias y mantendremos las observaciones anómalas en la BBDD.

Análisis de Componentes Principales

Tratamiento de los datos

El siguiente paso crítico es entender **cómo se relacionan las variables entre sí**. Esto nos permite detectar dos cosas importantes: la redundancia/colinealidad y la asociación con la variable target. Si dos variables numéricas están muy correlacionadas, podríamos eliminar una de ellas para simplificar el modelo predictivo o agruparlas en una variable latente que recoge la información de las dos, usando PCA. Para la asociación, podemos observar si variables concretas discriminan bien nuestra variable objetivo (**diabetes**).

Después de un análisis bivariado de las dos variables categóricas, se observa que la variable **vegdiet** es totalmente inútil para predecir si alguien tendrá diabetes, debido a que los perfiles de filas son iguales independientemente de la dieta del paciente. Podría ser candidata a ser desechada sin afectar al aprendizaje general.

Para la ejecución del modelo PCA, se han seleccionado exclusivamente las *variables de naturaleza numérica*, ya que este análisis se basa en el cálculo de varianzas y covarianzas que requieren datos continuos. Se han excluido las variables categóricas, como la dieta (**vegdiet**) por las razones mencionadas antes y el diagnóstico final (**diabetes**), con el fin de que la estructura de las componentes principales se construya únicamente a partir de los biomarcadores metabólicos y antropométricos. Esto nos permitirá observar cómo la variabilidad biológica de las pacientes agrupa los datos de forma natural antes de contrastarlos con el diagnóstico real.


Como hemos visto antes, no hay valores faltantes ni variables que tienen baja variabilidad, y tampoco vamos a incluir las variables categóricas, entonces no hace falta aplicar la función **Preparing()** de la librería *PLSandO* para limpiar los datos.

Como se observa en el resumen estadístico de los datos, las variables presentan rangos muy dispares (p.ej., la **insulin** varía entre 14 y 744, mientras que **pedigree** se mueve entre 0.085 y 2.42). Por ello, aplicaremos un escalado unitario en el modelo para evitar que las variables con magnitudes mayores dominen artificialmente la varianza del modelo, permitiendo que cada biomarcador tenga el mismo peso específico. También, escalamos las variables.

Selección del número de componentes principales

Aplicamos la función **pca()** sobre las variables numéricas seleccionadas. La función las centra y las escala a varianza unitaria. También, se estimará el máximo número de PCs posible.

Para decidir el número de PCs a retener, vamos a mirar el *scree plot* y también la tabla con la varianza explicada por cada PC y la acumulada.



comp	eigenVal	percVar	cumPercVar
1	2.9729702	27.0270	27.0270
2	1.7285847	15.7144	42.7414
3	1.2534700	11.3952	54.1366
4	0.9949014	9.0446	63.1811

Vamos a retener aquellas PCs que expliquen más varianza que la media, representada por la línea roja en el gráfico, entonces elegiríamos 3 PCs, aunque la PC 4 está muy cerca también. Usando el criterio del codo nos quedamos con 4 PCs que explican un 63.2% de la varianza total de los datos.

Ahora, vamos a visualizar las PCs seleccionadas para ver si hay una componente que no nos aporta información. Vamos a mirar el gráfico de scores para ver la dispersión de los pacientes en el espacio y el gráfico de correlación de las variables para ver cuáles influyen en las 4 PCs.


En las 2 primeras PCs observamos algunos pacientes un poco más alejados que el resto, y uno en la componente 3, que puede ser las variables **insulin**, **pedigree** o **glucose**. Veremos más adelante si se pueden considerar anómalos y qué hacemos con ellos.

La componente 4 es recogida totalmente por la variable **leptin**, la variable que mide la saciedad y el gasto energético. Como hemos visto antes, tiene algunas observaciones fuera del rango esperado, las cuales podrían influir en el modelo. Vamos a investigar si esas observaciones afectan al modelo o son valores anómalos.

Validación del modelo

Detección de anómalos moderados con la distancia al modelo (SCR)

Para detectar las observaciones (pacientes) que no están bien explicadas por nuestro modelo PCA, estudiaremos sus distancias al modelo mediante la Suma de Cuadrados Residual (SCR)




Hay 21 pacientes que se salen fuera del límite del 95%, y 5 fuera del límite del 99%. Veamos qué variables contribuyen más a las anomalías de los pacientes con mayor SCR: r54, r764, r126.

Después de investigar dónde sitúan las observaciones, no representan valores anómalos debido a que representan variabilidad biológica real. Las observaciones r54 y r764 presentan mayor edad, pero no es un error en los datos. No excluirémos estos anómalos moderados de momento.

Detección de anómalos severos con T2-Hotelling

Para identificar los valores anómalos severos (los que sesgan la creación de las PCs), usamos el estadístico T^2 de Hotelling. Si una observación salen fuera de los límites y además tienen baja SCR, se considera un anómalo severo.




Se detectaron 15 anómalos severos mediante el estadístico T^2 de Hotelling al 99% de confianza. Se procedió

a eliminar esas observaciones de la base de datos y creó un nuevo modelo PCA sin ellas. Al comparar los resultados, se observó que la varianza explicada y la orientación de las cargas permanecen invariantes. Esto demuestra que el modelo es robusto y que la estructura biológica detectada no depende de casos aislados, sino que representa la tendencia general de la muestra.

Dado que el modelo PCA muestra robustez frente a la presencia de valores extremos y asimetría en variables como la *insulina* y *leptina*, no hace falta aplicar transformaciones para suavizar los anómalos, garantizando que la interpretación de los resultados del modelo sea directa.


Interpretación del modelo

Para analizar la relación de cada variable en las componentes, hemos representado los pesos de las características en cada dimensión retenida.



En la primera componente, *leptin* está relacionada negativamente con el resto de las variables. En la segunda componente, *mass*, *CRP*, *triceps*, *pedigree*, y *leptin* están relacionadas positivamente entre sí, mientras que están relacionada negativamente con las variables *pregnant*, *age*, *cholesterol*, *pressure*, y *glucose*. La variable *insulin* no tiene influencia en esa componente. La tercera componente recoge las variables *insulin*, *glucose*, y *pedigree* contra el resto de las variables, menos *leptin* que no influye. La cuarta componente tiene como líder *leptin*, junto con *pregnant*, *pressure*, *edad* y *triceps*. *Cholesterol* y *glucose* están relacionados negativamente con las demás, menos *CRP*, *insulin*, *mass* y *pedigree* casi no influyen.

Para ver el porcentaje de variabilidad de cada variable que queda explicado por el modelo PCA (63.2), vamos a mirar el gráfico R^2 .



Es claro que la mayoría de la componente 4 está explicado por **leptin**, pero **cholesterol** y **pregnant** también son importantes. **Insulin** y **glucose** son quienes más contribuyen en la tercera componente, mientras que en la segunda son **pregnant** y **edad**. Finalmente, la primera componente está bien explicada por muchas variables, lo que tiene sentido porque explica el mayor porcentaje de variabilidad.

Al analizar estos gráficos de las 4 componentes principales retenidas, podemos dar una interpretación clínica a cada una de ellas. La componente 1 explica 27.03% de la variabilidad de los datos, y todos sus loadings menos uno son positivos. Sus variables más contribuyentes captura un factor de obesidad y distribución de grasa en el cuerpo. Valores altos en la PC1 corresponden a pacientes con un peor estado metabólico general, con mayor peso, inflamación, y niveles de glucosa, que son factores importantes de riesgo para la diabetes. Explica 15.71% de la variabilidad total de los datos. Las variables de edad y número de embarazos contrastan fuertemente frente a marcadores de obesidad y grasa en la segunda componente. Esta diferencia los pacientes jóvenes sin hijos pero con mayor grado de obesidad y/o inflamación con los pacientes mayores con hijos pero con menor grasa. La componente 3 recoge 11.4% de la variabilidad y enfoque en la separación entre los niveles de insulina y glucosa con la historia familiar con el riesgo cardiovascular tradicional. Indica la existencia de dos perfiles clínicos distintos entre los pacientes con riesgo biológico. Finalmente, la PC4 explica 9.0% de la variabilidad y está dominada casi enteramente por la **leptin**, con una poca contribución de **cholesterol** en la dirección opuesta. Esto sugiere que la variabilidad de la hormona que regula la saciedad tiene una evolución bastante independiente al resto de marcadores de sobrepeso.

Conclusiones

El Análisis de Componentes Principales ha permitido sintetizar la alta dimensionalidad de los 11 biomarcadores y características demográficas en tan solo **4 nuevas variables latentes (PCs)**, reteniendo aproximadamente el **63%** de la variabilidad original.

Hemos demostrado que las diferentes medidas clínicas están correlacionadas y se agrupan en perfiles clínicos bien diferenciados: un estado metabólico adverso/obesidad general (PC1), un eje de edad y factores vinculados al embarazo frente a fenotipos con alta adiposidad independiente de la edad (PC2), la diferenciación entre vías ligadas a resistencia a la insulina cardiometabólico y vías ligadas a factores genéticos/glucémicos (PC3) y una vía independiente liderada por la leptina (PC4).

Esta reducción no solo simplifica la complejidad del conjunto de datos, sino que elimina el ruido introducido por variables fuertemente ligadas entre sí (colinealidad). Además proporciona características ortogonales e interpretables, ideales para entrenar modelos predictivos (por ejemplo, para clasificar si una paciente padece diabetes o no), disminuyendo el riesgo de sobreajuste.

Reglas de asociación

Para complementar el análisis, sería muy bien aplicar reglas de asociación para encontrar patrones y entender el comportamiento de los pacientes, especialmente con respecto a nuestro objetivo de entender por qué un paciente tiene diabetes o no. Para hacer eso, requiere discretizar las variables numéricas para tratarlas como categóricas ordinales. Con esto, podemos trabajar con los distintos niveles y descubrir las reglas de asociación.

Para discretizar las variables, se ha basado los niveles en umbrales médicos ya establecidos. Esas variables son: `glucose`, `mass`, `age`, y `pressure`. El resto de variables no tienen umbrales establecidos, por lo tanto usamos la función `discretizeDF()` de la librería *arules*. Se dividió esas variables en tres niveles (“Bajo”, “Medio”, “Alto”) por frecuencia para tenerlos equilibrados. Como hemos visto antes, la variable `vegdiet` es independiente de si los pacientes tienen diabetes o no, entonces la excluimos también.

A continuación aplicamos el algoritmo a priori, con un soporte mínimo de 0.001 y una confianza mínima de 0.8. Además, como nos interesa ver el comportamiento de diabetes, miramos solo las reglas que contiene diabetes en el consecuente. Primero, analizamos los factores de riesgo para desarrollar diabetes, incluyendo que el paciente sí tiene diabetes como el consecuente.

Después de eliminar las reglas redundantes, hemos obtenido un total de 3698 reglas. Ordenamos las reglas por su **lift** y miramos las 5 reglas con más lift.

##	lhs	rhs	support	confidence	coverage	lift	count
## [1]	{pressure=Pres_Hiper, age=Edad_Adulto}	=> {diabetes=pos}	0.013477089	1	0.013477089	3.01626	5
## [2]	{pressure=Pres_Hiper, triceps=Medio (24-33]}	=> {diabetes=pos}	0.010781671	1	0.010781671	3.01626	4
## [3]	{pressure=Pres_Hiper, age=Edad_Senior, leptin=Medio (7.64-10.19]}	=> {diabetes=pos}	0.002695418	1	0.002695418	3.01626	1
## [4]	{pressure=Pres_Hiper, pedigree=Alto (0.59-2.42], age=Edad_Senior}	=> {diabetes=pos}	0.002695418	1	0.002695418	3.01626	1
## [5]	{pressure=Pres_Hiper, insulin=Medio (94-168], age=Edad_Senior}	=> {diabetes=pos}	0.002695418	1	0.002695418	3.01626	1

Las reglas tienen el mismo lift: 3.01626. Esto significa que todos los antecedentes y tener diabetes son dependientes y son reglas útiles. Su interpretación es que teniendo las características del antecedente, es 3 veces más probable tener diabetes que tener diabetes en general. Por ejemplo, en la primera regla dice “si un paciente tiene hipertensión y es adulto (entre 35 y 45 años), es 3 veces más probable tener diabetes que un paciente en general”.

Si el paciente es mayor de 35 años, es probable que tiene diabetes. Como vimos en el PCA, la edad influye mucho. Las otras variables importantes aquí son: `triceps`, `leptin`, `pedigree`, y `insulin`. Estas reglas respaldan el análisis del modelo PCA.

Ahora, para investigar los niveles ideales para no tener diabetes, poniendo el consecuente como no tener diabetes.

##	lhs	rhs	support	confidence	coverage	lift	count
## [1]	{pressure=Pres_Hiper, mass=IMC_Normal [18-25]}	=> {diabetes=neg}	0.002695418	1	0.002695418	1.495968	
## [2]	{glucose=Glu_Normal [56-100], pressure=Pres_Hiper}	=> {diabetes=neg}	0.008086253	1	0.008086253	1.495968	
## [3]	{pressure=Pres_Hiper,						


```

##      triceps=Bajo [7-24]}          => {diabetes=neg} 0.013477089      1 0.013477089 1.495968
## [4] {mass=IMC_Normal [18-25],      => {diabetes=neg} 0.008086253      1 0.008086253 1.495968
##      age=Edad_Senior}
## [5] {pregnant=Bajo [0-1],          => {diabetes=neg} 0.002695418      1 0.002695418 1.495968
##      age=Edad_Senior}

```

Podemos ver que hipertensión aparece en esas reglas también, indicando que el hecho de tener hipertensión no significa que el paciente tiene diabetes o no, sino que el médico tiene que mirar las otras características del paciente. Lo mismo con la edad. El resto de las variables están dentro del rango normal, incluso en el nivel bajo, indicando que un médico debe estar alerta si los niveles empiezan a subir para prevenir diabetes antes.

Usando las reglas de asociación, podemos ver las relaciones entre diabetes y marcadores biológicos para crear planes de prevención para pacientes basándose en sus características individuales.